ENCG
Settat

جامعة الحسن الأول
UNIVERSITÉ HASSAN 1ER



RÉGIMES DE MARCHÉ PAR PARTITIONNEMENT

ÉTUDE DU S&P500 À L'AIDE DE MÉTHODES DE CLUSTERING : K-MEANS ET GMM

PRÉPARÉ PAR

FADAL DIAE EDDINE

IKRAM SAMI

DATA SCIENCE

2026/2027

SOMMAIRE

Introduction 1

Données et préparation 2

Construction des variables financières 3

Standardisation et choix du nombre de groupes 4

Identification des régimes avec K-Means 5

Comparaison avec Gaussian Mixture Model (GMM) 6

Régimes et récessions : interprétation 7

Conclusion générale, limites et perspectives 8

INTRODUCTION

1.1 Contexte

Les marchés financiers ne présentent pas toujours le même comportement. Certaines périodes sont relativement stables, tandis que d'autres sont marquées par des variations importantes et une incertitude plus élevée. Repérer ces changements de comportement peut aider à mieux décrire l'environnement financier et à comprendre comment le risque évolue dans le temps.
Le S&P500 est un indice représentatif de grandes entreprises cotées aux États-Unis. Dans ce projet, son évolution quotidienne sert de base à l'identification de différents régimes de marché. L'analyse est complétée par l'indicateur USREC de FRED, qui signale les périodes de récession aux États-Unis.

1.2 Problématique

La question principale est la suivante : peut-on distinguer automatiquement des périodes de marché relativement calmes et des périodes de forte instabilité à partir du rendement et de la volatilité récents du S&P500 ?
Une deuxième question consiste à examiner si les périodes classées comme très volatiles coïncident davantage avec les mois identifiés comme récessifs.

1.3 Objectifs

- Collecter et préparer les séries du S&P500 et de l'indicateur USREC.
- Calculer des indicateurs quotidiens de rendement et de volatilité sur une fenêtre de 20 séances.
- Standardiser ces indicateurs à partir de leur historique récent sur 252 jours.
- Déterminer le nombre de groupes à retenir, puis appliquer K-means.
- Comparer les résultats de K-means à ceux d'un modèle Gaussian Mixture Model (GMM).
- Étudier le lien entre les régimes identifiés et l'indicateur de récession.

DONNÉES ET PRÉPARATION

2.1 Sources des données

Le notebook télécharge deux séries au format CSV depuis FRED (Federal Reserve Economic Data). La première, SP500, correspond au niveau quotidien de l'indice S&P500. La seconde, USREC, est un indicateur mensuel de récession : la valeur 1 indique une récession et la valeur 0 indique l'absence de récession.

2.2 Chargement et nettoyage

La bibliothèque pandas est utilisée pour lire les fichiers CSV. La date est convertie en index temporel grâce à parse_dates=True. Pour le S&P500, les valeurs sont converties en format numérique. Les symboles « . », qui représentent des observations non disponibles dans le fichier, sont transformés en valeurs manquantes avec errors='coerce', puis supprimés avec dropna().
Cette étape permet de conserver les jours pour lesquels un niveau de l'indice est effectivement disponible. L'indicateur USREC est chargé séparément, car sa fréquence est mensuelle et non quotidienne.

2.3 Contrôles effectués et volume

L'exécution indique 2 513 observations quotidiennes pour le S&P; 500, du 7 novembre 2016 au 5 novembre 2026. La série USREC contient 2 063 observations mensuelles. Le notebook affiche également les valeurs de USREC de décembre 2019 à août 2020 : les mois de mars et avril 2020 sont codés 1, tandis que les autres mois affichés sont codés 0.
les deux sources n'ont pas la même fréquence. Le notebook conserve le S&P500 en quotidien et adapte ensuite l'indicateur mensuel de récession à chaque date quotidienne.

CONSTRUCTION DES VARIABLES FINANCIÈRES

3.1 Rendement quotidien

Le rendement quotidien est calculé avec pct_change(). Il mesure la variation relative du niveau du S&P500 par rapport à la séance précédente : rendement(t) = [indice(t) / indice(t−1)] − 1. Le premier rendement ne peut pas être calculé, car il n'existe pas de séance précédente dans la série.

3.2 Volatilité et rendement moyen sur 20 jours

Le notebook utilise une fenêtre glissante de 20 observations. La volatilité vol20 est l'écart-type des rendements quotidiens sur les 20 dernières séances. La variable mean20 est la moyenne des rendements sur cette même fenêtre. La volatilité donne une indication de l'ampleur des fluctuations récentes, tandis que le rendement moyen résume leur direction moyenne.

3.3 Résultats descriptifs

Après le calcul des indicateurs et la suppression des lignes incomplètes, le tableau feat contient 2493 observations et deux variables. La volatilité moyenne sur 20 jours est de 0,009440, soit environ 0,944 % en unité de rendement. Le rendement moyen sur 20 jours est de 0,000570, soit environ 0,057 % par jour en moyenne sur les fenêtres observées.

Statistique	Volatilité (vol20)	Rendement moyen (mean20)
Moyenne	0,009440	0,000570
Écart-type	0,006550	0,002223
Minimum	0,002072	−0,016943
Médiane	0,007759	0,000860
Maximum	0,061182	0,010814

STANDARDISATION ET CHOIX DU NOMBRE DE GROUPES

4.1 Pourquoi standardiser ?

Les deux variablesne présententpas nécessairement la même échelle ni la même dispersion. La standardisation permet de les exprimer par rapport à leur comportement historique récent. Le notebook utilise une fenêtre de 252 observations, correspondant approximativement à une année de séances boursières.

4.2 Calcul du Z-score glissant

Pour chaque date, le code calcule la moyenne et l'écart-type des 252 observations précédentes, puis applique la formule **Z = (valeur actuelle − moyenne passée) / écart-type** passé. L'utilisation de shift(1) décale les statistiques d'une période : la date courante n'entre donc pas dans le calcul de sa propre référence historique. Les premières observations sans historique suffisant sont supprimées.
Après cette opération, la matrice Z contient 2 241 observations et deux variables. Les valeurs standardisées indiquent si la volatilité ou le rendement moyen du moment est supérieur ou inférieur à sa référence historique récente.

4.3 Sélection de K avec le score de silhouette

Le notebook teste **K-means** pour un nombre de groupes K compris entre 2 et 5. Le score de silhouette évalue dans quelle mesure les observations sont proches de leur propre groupe et éloignées des autres. Dans cette comparaison, le score le plus élevé est obtenu pour K = 2.

Nombre de groupes	Score de silhouette
K = 2	0,564
K = 3	0,501
K = 4	0,400
K = 5	0,342

Le projet retient donc deux régimes. Ce choix est celui qui maximise le score de silhouette parmi les quatre valeurs testées ; il ne signifie pas que deux régimes constituent une description exhaustive de tous les comportements possibles du marché.

IDENTIFICATION DES RÉGIMES AVEC K-MEANS

5.1 Principe et application

K-means est une algorithme de clustering non supervisé. Il répartit les observations en K groupes en cherchant à approcher les observations d'un même groupe autour de leur centre. Le modèle final est entraîné sur les deux variables standardisées de Z, avec K = 2, n_init = 10 et random_state = 42. Le paramètre random_state rend l'exécution reproductible dans les mêmes conditions.

5.2 Attribution de noms aux groupes

Les numéros de clusters produits par K-means n'ont pas de signification économique directe. Le notebook calcule donc la volatilité moyenne vol20 dans chaque groupe, classe les groupes du moins volatil au plus volatil, puis leur attribue les noms « Calme » et « Tempête ». Les statistiques présentées ensuite sont calculées à partir des variables d'origine, non standardisées.

5.3 Résultats obtenus

Régime	Volatilité moyenne	Rendement moyen	Nombre de jours
Calme	0,008442	0,001248	1 811
Tempête	0,016693	−0,002363	430

Le régime Calme représente environ 80,8 % des 2 241 observations analysées. Sa volatilité moyenne est de 0,844 % et son rendement moyen sur 20 jours est positif (environ 0,125 %). Le régime Tempête représente environ 19,2 % des observations. Sa volatilité moyenne est de 1,669 %, soit près du double de celle du régime Calme, et son rendement moyen sur 20 jours est négatif (environ −0,236 %).

Interprétation : dans cet échantillon, le régime Tempête correspond à des périodes plus volatiles et associées à un rendement moyen plus faible. Il s'agit d'une association descriptive, pas d'une preuve de causalité ni d'une prévision.

COMPARAISON AVEC GAUSSIAN MIXTURE MODE

6.1 Présentation du GMM

Le Gaussian Mixture Model est une méthode de clustering probabiliste. Il représente les données comme un mélange de distributions gaussiennes et estime, pour chaque observation, sa probabilité d'appartenir à chacun des groupes. Le notebook ajuste un GMM avec le même nombre de composantes que K-means, soit deux, avec n_init = 5 et random_state = 42.

6.2 Comparaison quantitative

Indicateur	K-means	GMM
Observations classées Calme	1 811	1 636
Observations classées Tempête	430	605
Score de silhouette	0,564	0,489

Le GMM classe davantage de jours en Tempête que K-means : 605 contre 430. Son score de silhouette est inférieur (0,489 contre 0,564), ce qui indique une séparation moins nette selon cette mesure sur les étiquettes produites.

6.3 Accord entre les deux méthodes

L'indice Adjusted Rand Index (ARI) mesure la similarité entre deux partitions en corrigeant l'accord attendu par hasard. Le notebook obtient un ARI de 0,687. Les deux méthodes présentent donc un accord notable, mais leurs classifications ne sont pas identiques. Le tableau croisé montre que 1 636 observations sont classées Calme par les deux méthodes, 430 sont classées Tempête par les deux méthodes et 175 classées Calme par K-means sont classées Tempête par GMM. Aucun des 430 jours Tempête de K-means n'est classé Calme par GMM.
La certitude moyenne maximale du GMM est de 0,905. Elle correspond à la moyenne, sur les observations, de la probabilité la plus élevée attribuée par le modèle. Cette valeur décrit la confiance probabiliste interne du GMM elle ne constitue pas une mesure indépendante de l'exactitude des classifications.

Dans les résultats du notebook, K-means obtient le meilleur score de silhouette. Le GMM apporte une lecture probabiliste et identifie un ensemble plus large de jours Tempête. Le choix du modèle dépend donc de l'objectif : séparation des groupes ou estimation probabiliste de l'appartenance.

RÉGIMES ET RÉCESSIONS : INTERPRÉTATION

7.1 Mise en correspondance avec USREC

Pour comparer les régimes quotidiens à l'indicateur mensuel, le notebook transforme les dates de USREC en périodes mensuelles, puis attribue à chaque date quotidienne la valeur correspondant à son mois. Les valeurs manquantes sont remplacées par 0 avec fillna(0). Cette règle doit être gardée à l'esprit, notamment pour les mois récents pour lesquels l'indicateur n'est pas encore disponible.

7.2 Tableau des observations

Régime K-means	Hors récession (0)	Récession (1)
Calme	1 798	13
Tempête	400	30
Total	2 198	43

En pourcentage des observations de chaque colonne, le notebook obtient : hors récession, 81,8 % des jours sont Calme et 18,2 % Tempête ; pendant les récessions, 30,2 % des jours sont Calme et 69,8 % Tempête. Dans l'échantillon étudié et selon l'alignement retenu, le régime Tempête est donc proportionnellement beaucoup plus présent pendant les mois codés comme récessifs.

7.3 Évolution annuelle du régime Tempête

Le nombre dejoursclassés Tempête par annéeest le suivant : 2018 : 95 ; 2019 : 23 ; 2020 : 35 ; 2021 : 31 ; 2022 : 125 ; 2024 : 44 ; 2025 : 55 ; 2026 : 22. Les années absentes du résultat affiché ne présentent aucun jour Tempête dans le regroupement annuel affiché. L'année 2026 est partielle puisque les données s'arrêtent au 5 novembre 2026.

7.4 Lecture du graphique final

Le dernier graphique représente le niveau du S&P500 dans le temps. Les points sont colorés selon le régime K-means : vert pour Calme et rouge pour Tempête. Des bandes grises signalent les périodes de récession selon USREC. Cette visualisation permet de confronter l'évolution de l'indice, les régimes détectés et les mois récessifs sur une même chronologie.

Association et prudence : le tableau montre une coïncidence statistique dans les données utilisées. Il ne permet pas, à lui seul, d'affirmer que les récessions causent les épisodes de volatilité ou que le modèle peut anticiper les récessions.

CONCLUSION GÉNÉRALE, LIMITES ET PERSPECTIVES

Ce projet a mis en place une démarche de Data Science pour identifier des régimes de marché à partir des données quotidiennes du S&P; 500. Après le chargement et le nettoyage des données, deux indicateurs ont été construits : la volatilité et le rendement moyen sur 20 séances. Ils ont ensuite été standardisés par rapport aux 252 observations précédentes afin de décrire les conditions du marché relativement à son passé récent.

Le test des valeurs de K entre 2 et 5 a conduit à retenir deux groupes, avec un score de silhouette de 0,564 pour K = 2. K-means a identifié un régime Calme de 1 811 jours et un régime Tempête de 430 jours. Le régime Tempête présente une volatilité moyenne plus élevée et un rendement moyen plus faible. La comparaison avec le GMM montre un accord partiel important (ARI = 0,687), mais le GMM attribue davantage d'observations au régime Tempête.

Enfin, le rapprochement avec USREC indique que 69,8 % des jours observés pendant les mois codés comme récessifs sont classés Tempête, contre 18,2 % des jours hors récession. Ces résultats suggèrent que les régimes identifiés capturent une partie des épisodes de tension du marché. Ils répondent ainsi à l'objectif descriptif du projet.

8.2 Limites à considérer

•Le nombre de groupes est choisi uniquement parmi K = 2, 3, 4 et 5 et à partir du score de silhouette, d'autres critères ou périodes pourraient conduire à un autre choix.

• L'analyse repose sur deux variables calculées à partir du S&P500. D'autres facteurs financiers ou macroéconomiques ne sont pas intégrés.

• USREC est mensuel alors que les régimes sont quotidiens. Le remplacement des valeurs manquantes par 0 peut classer comme hors récession des mois dont l'information n'est pas encore disponible.

• Les résultats dépendent de la période observée et des paramètres des algorithmes. Ils ne doivent pas être interprétés comme des conseils d'investissement.

8.3 Améliorations possibles

• Tester la stabilité des régimes sur plusieurs périodes et avec d'autres fenêtres de calcul.
• Comparer d'autres nombres de clusters et d'autres méthodes de regroupement.
• Étudier les probabilités d'appartenance du GMM au fil du temps, plutôt que la seule classe la plus probable.
• Améliorer le traitement des données macroéconomiques mensuelles et documenter explicitement les mois sans
information.
• Ajouter une validation temporelle si l'objectif évolue vers la détection en temps réel ou la prévision.

En conclusion, le notebook fournit une première segmentation lisible du marché en deux régimes, Calme et Tempête. Les résultats montrent que le régime le plus volatil est davantage représenté pendant les mois de récession de l'échantillon. Cette approche constitue un outil d'analyse exploratoire utile, à compléter par des tests de robustesse avant toute utilisation opérationnelle.